

ACTIVIDAD 1

MINERÍA DE CONOCIMIENTO

Polish Companies Bankruptcy



POR:

Sánchez Troncoso,
Pablo

DNI:



Tabla de contenidos

Tabla de contenidos.....	2
Introducción.....	3
Metodología.....	3
Comprensión del Negocio.....	3
Comprensión de los Datos.....	3
Preparación de los Datos.....	3
1. Lectura.....	3
2. Preprocesamiento.....	3
1. Filtrado de filas.....	3
2. Escala logarítmica.....	4
3. Valores atípicos.....	4
1. Límite simétrico.....	4
2. Límite asimétrico inferior.....	4
3. Límite asimétrico superior.....	5
4. Valores faltantes.....	5
5. Normalización.....	5
Modelado.....	5
- Árbol de decisión.....	5
- Vecinos más cercanos.....	5
- Bayesiano ingenuo.....	5
Evaluación.....	5
Conclusión.....	6

Introducción

Diseño de un modelo predictivo que genere 5 predicciones para los datos de empresas polacas. Cada predicción se corresponderá con un horizonte temporal distinto (1 año, 2 años, 3 años, 4 años y 5 años), relacionada con la información relativa a los 5 datasets, cuya variable objetivo (class) indica si la empresa entró (1) o no (0) en quiebra.

Metodología

Se ha optado por seguir la metodología CRISP-DM. Está estructurada en seis fases distintas, cada una de las cuales representa una etapa clave en el proceso de desarrollo de un proyecto de minería de datos.

Comprensión del Negocio

Consiste en elaborar un **modelo predictivo** que a partir de una serie de **datos económicos de una empresa** prediga si ésta entrará en quiebra.

Comprensión de los Datos

El conjunto de datos trata sobre la **predicción de quiebras de empresas polacas** a través de datos económicos.

Las empresas en quiebra se analizaron en el período 2000-2012, mientras que las empresas que aún estaban en funcionamiento se evaluaron entre 2007 y 2013.

Preparación de los Datos

Consta de dos fases:

1. Lectura

Durante esta fase, se lleva a cabo la **integración de los cinco conjuntos de datos en una sola tabla**, donde se añade una **columna adicional que identifica la**

procedencia de cada fila según el conjunto de datos correspondiente.


2. Preprocesamiento

Consta de cinco pasos:

1. Filtrado de filas

Consta del **filtrado de filas que contienen un número excesivo de valores faltantes**. Para determinar qué cantidad de valores faltantes por fila se considerará como excesiva, es necesario establecer un criterio específico.

Dada la figura, se ha utilizado el criterio de **más de cinco** valores faltantes por fila.



2. Escala logarítmica

Tras un breve análisis de las **características** mediante histogramas se ha concluido que estos **abarcan un rango muy amplio de valores**.

Por ello, se ha decidido aplicar una **escala logarítmica para reducir el impacto de los valores atípicos**.

La escala usada **está centrada en la mediana**; y se define como:

$$f(x) = \begin{cases} -\ln(1 - x + y), & \text{si } x < y \\ \ln(1 + x - y), & \text{si } x > y \\ 0, & \text{si } x = y \end{cases}$$

Donde x es el valor actual e y es la mediana.

3. Valores atípicos

Cómo se tratan de datos de medidas económicas; descarta que los valores atípicos puedan ser causa de errores de medición. Sin embargo, pueden ser causa de **errores humanos, errores de manipulación de datos, errores de muestreo y/o no ser errores** (sino sólo **valores extremos**)

Se ha asumido que en la mayoría de casos no son errores, sino valores extremos.

Por esta razón se han usado **tres tipos de tratamientos de valores atípicos en función de la posición de la cola de la distribución**.


Es por ello que la opción de tratamiento tomada consiste en **reemplazar los valores atípicos con el valor permitido más cercano**.

También se ha tenido en cuenta si dichas distribuciones presentan sesgo (izquierda o derecha) o no. **Si presentan sesgo se ha modificado el multiplicador del rango intercuartílico k** . Aunque siempre manteniendo una amplitud de 4 unidades.

Las estrategias usadas son:


1. Límite simétrico

Aplicada a distribuciones **no sesgadas**: $k = 2$ en ambos límites.




2. Límite asimétrico inferior

Aplicada a distribuciones **sesgadas a la izquierda**: $k = 2.5$ en límite inferior, $k = 1.5$ en límite superior.



3. Límite asimétrico superior

Aplicada a distribuciones **sesgadas a la derecha**: $k = 1.5$ en límite inferior, $k = 2.5$ en límite superior.



4. Valores faltantes

Se ha decidido por **reemplazar los valores faltantes por la mediana**.

5. Normalización

Se ha optado por una normalización **mínimo-máximo** en el rango $(-1, +1)$ para la eliminación de la escala.

Modelado

En la etapa de modelado se ha usado una **validación cruzada de diez pliegues usando muestreo estratificado**.

Además como se trata de un conjunto de **datos desbalanceados** se ha decidido aplicar la técnica **SMOTE para balancear el set de datos de entrenamiento** y así tratar de **evitar el sesgo de mayoría**.

Tras esto, se han escogido técnicas técnicas con la que se han probado diferentes parámetros.

Estás son:

- Árbol de decisión

De todas las parametrizaciones probadas; la mejor encontrada usa:

Índice de Gini como medida de calidad, **mínimo siete registros por nodo** y el **punto de división promedio**.

- Vecinos más cercanos

De todas las parametrizaciones probadas; la mejor encontrada usa:


Distancia de Mahalanobis (Mejor que: Euclídea, Manhattan y Chebyshev), **siete vecinos** y **ponderación de vecinos por distancia**.

- Bayesiano ingenuo

La parametrización por defecto es la mejor encontrada.

Evaluación


Tras el modelado, se evaluaron las tres técnicas con todos los datos del conjunto de datos. De esta forma, **nos quedaremos con los dos mejores métodos en promedio**.




Conclusión

Después de la evaluación, se determinó que los dos mejores métodos son: **Árbol de decisión** y **Vecinos más cercanos**.


- Primer año




- Cuarto año




- Segundo año



- Quinto año



- Tercer año



- Todos los años

