


ACTIVIDAD 2

MINERÍA DE CONOCIMIENTO

Polish Companies Bankruptcy



POR:	
Sánchez Troncoso, Pablo	
DNI:	

Tabla de contenidos

Tabla de contenidos.....	2
Contexto.....	3
Metodología.....	3
Objetivo del negocio.....	3
Descripción de los datos.....	3
Preparación de los Datos.....	3
1. Valores atípicos.....	3
2. Valores faltantes.....	4
3. Normalización.....	4
4. Balanceo.....	4
5. Reducción de dimensionalidad.....	4
Técnicas predictivas.....	5
- Árbol de decisión.....	5
- Random Forest.....	5
- Boosting.....	5
- Boosting.....	5
Técnicas de validación.....	5
Resultados.....	6
Mejoras.....	6

Contexto

Diseño de un modelo predictivo que genere 5 predicciones para los datos de empresas polacas. Cada predicción se corresponderá con un horizonte temporal distinto (1 año, 2 años, 3 años, 4 años y 5 años), relacionada con la información relativa a los 5 datasets, cuya variable objetivo (class) indica si la empresa entró (1) o no (0) en quiebra.

Metodología

Se ha optado por seguir la metodología CRISP-DM. Está estructurada en seis fases distintas, cada una de las cuales representa una etapa clave en el proceso de desarrollo de un proyecto de minería de datos.

Objetivo del negocio

Consiste en elaborar un **modelo predictivo** que a partir de una serie de **datos financieros de empresas prediga si ésta entrará en quiebra**.

Descripción de los datos

Las empresas en quiebra se analizaron en el período 2000 - 2012, mientras que las empresas que aún estaban en funcionamiento se evaluaron entre 2007 y 2013.

Los datos financieros corresponden a un período de cinco años, con etiquetas indicando quiebras de empresas después de diferentes periodos. Se detalla el número de casos y las quiebras por año:

Año	Casos	Quiebras
1.º	7.027	271
2.º	10.173	400
3.º	10.503	495
4.º	9.792	515
5.º	5.910	410


Preparación de los Datos

1. Valores atípicos

Para su cómputo, se ha usado el método de los cuartiles. Que es una técnica de univariante.

Pueden ser causa de **errores humanos, errores de manipulación de datos, y/o no ser errores sino sólo valores extremos**.

Outliers Count per Year



Tras un breve análisis de las **características** mediante box plots se ha concluido que estas **abarcen un rango muy amplio de valores**.

Por ello, se ha decidido aplicar una **escala logarítmica para reducir el impacto de los valores atípicos**.

La escala usada **está centrada en la mediana**; y se define como:


$$f(x) = \begin{cases} -\log(1 - x + \text{Med}(x)) & \text{si } x < \text{Med}(x) \\ \log(1 + x - \text{Med}(x)) & \text{si } x > \text{Med}(x) \\ 0 & \text{si } x = \text{Med}(x) \end{cases}$$

Por esto, la estrategia de tratamiento empleada consiste en **el reemplazo de los valores atípicos por valores faltantes**.

2. Valores faltantes

Algunas de las características presentan distribuciones bimodales. En algunas de estas cada clase pertenece a una moda distinta. Por esto, la estrategia de tratamiento empleada consiste en la **asignación estratificada de la mediana**.

Missing Values Count per Year




3. Normalización

Como algunas técnicas empleadas más adelante hacen uso de medidas de distancia se ha concluido aplicar la **normalización** de las características para la **eliminación de la escala**.

4. Balanceo


Dado el siguiente gráfico se ha determinado que **los conjuntos de datos están desbalanceados**. Para evitar el **s sesgo de mayoría** se ha aplicado sobre **muestreo estratificado** usando la técnica de **SMOTE** para balancear las clases.



5. Reducción de dimensionalidad

Los conjuntos de datos presentan una gran cantidad de características. Para la **reducción del ruido** de otras características menos determinantes para la clasificación se ha aplicado una técnica de **selección de características** usando **algoritmos genéticos**.

Most Relevant Features



Técnicas predictivas

Se han aplicado las siguientes técnicas:

- **Árbol de decisión**

De todas las parametrizaciones probadas; la mejor encontrada usa:

Índice de Gini como medida de calidad, **mínimo seis registros por nodo** y el **punto de división promedio**.

- **Random Forest**

De todas las parametrizaciones probadas; la mejor encontrada usa:

Gain ratio como medida de calidad, **cincuenta modelos**, **mínimo seis registros por nodo**.

- **Boosting**

De todas las parametrizaciones probadas; la mejor encontrada usa:

Tres modelos, **Gain ratio** como medida de calidad, **mínimo seis registros por nodo** y el **punto de división promedio**.

- **Boosting**

De todas las parametrizaciones probadas; la mejor encontrada usa:

Cinco modelos, **Gain ratio** como medida de calidad, **mínimo seis registros por nodo** y el **punto de división promedio**.


Técnicas de validación

Se ha usado una **validación cruzada de diez pliegues usando muestreo estratificado**.


Resultados

Aparenta ser viable para su aplicación en un contexto real.


- Primer año




- Cuarto año




- Segundo año



- Quinto año



- Tercer año



Mejoras

- Clusterización para un tratamiento de valores atípicos multivariante.
- Búsqueda por similitud para el tratamiento de valores faltantes.
- Otras técnicas de reducción de dimensionalidad.